

Vehicle ReID: сборка, запуск и воспроизведение результатов

Сдаваемая конфигурация **d1_j48** объединяет две OSNet-AIN и whitening в один 512-мерный признак. В `submission.csv` каждый запрос независимо переранжируется по своим 50 ближайшим объектам статичной галереи; `candidates.csv` и HTTP-поиск используют косинусную близость. Здесь описаны архитектура, сборка и запуск Docker, форматы результатов, метрики и границы воспроизводимости. В репозиторий входят релизные веса, офлайн-зависимости и исходники обучения; для пересчёта метрик нужны изображения, которые организаторы передают отдельно. Проверка Docker Engine / Compose и её условия приведены в [отчёте](#). Исторические исследования и ограничения их повторения собраны в разделах 8–11.

Основной контейнер для стенда организаторов использует GPU NVIDIA через ONNX Runtime; заявленный стенд — RTX A5000 с CUDA 12.2 и доступом в Docker через `--gpus all` ([ответы организаторов, вопрос 30](#)). Отдельный CPU-образ сохраняет офлайн-воспроизведение опубликованных артефактов и работу прототипа на VPS без GPU. При запуске основного образа CUDA обязательна; фактические провайдеры обеих моделей записываются в `run_info.json` и `/api/version`. Числа качества ниже получены на CPU-релизе. Собранный GPU-образ (ONNX Runtime GPU 1.20.2) 29.09 дополнительно прогнан с принудительным CPU-провайдером: полный R-val и официальный `evaluate.py` воспроизвели все опубликованные числа точно ([протокол](#)). Исполнение на CUDA и замер скорости на RTX A5000 остаются непроверенными.

1. Назначение и архитектура

Сервис принимает изображение автомобиля и предоставленный bbox (x, y, w, h), извлекает признак, ищет похожие объекты в галерее и возвращает кандидатов либо пустой ответ. Сдаваемый признак — двумодельный ансамбль **d1_j48**: публичный OSNet-AIN (OMZ 2022.1) плюс наш дообученный OSNet-AIN **combined_v1** (LP-FT на RoundaboutHD, MIT + CARLA, Apache-2.0 + train организатора; журнал обучения — [training/combined/](#)), с общим whitening. OCR, распознавание номера и детекция автомобиля в вычислительный путь не входят; влияние области пластины исследовалось отдельно для обеих моделей ([training/combined/REPORT.md §5, plate-ablation/](#)).

Компонент	Код	Ответственность
Подготовка изображения	preprocess.py	Чтение JPEG/PNG, bbox, RGB, изменение размера
Модель	model.py	Проверка SHA-256 трёх файлов весов (две ONNX-модели + матрица whitening), выбор CUDA/CPU-провайдера ONNX Runtime, двумодельный признак со whitening
Пакетная обработка	batch.py	Последовательное чтение CSV, извлечение векторов, ранжирование, три сдаваемых файла
Переранжирование	rerank.py	Для каждого запроса отдельно: k-взаимные соседи среди его cosine top-50 и статичной галереи; старый общий алгоритм оставлен для исследований

Компонент	Код	Ответственность
HTTP API	main.py	Получение файла/bbox или вектора, валидация, поиск, OpenAPI
Галерея	store.py , Qdrant	Векторы и метаданные, точный поиск по косинусу
Загрузчик галереи	load_gallery.py	Извлечение признаков галереи и пересоздание коллекции Qdrant
Клиент	index.html	Страница браузера, выдаваемая API; отдельного frontend-контейнера нет
Измерения	reid_metrics.py , scope_metrics.py	Ранговые метрики, отказ, явные варианты протокола

API и Qdrant запускаются отдельными контейнерами. Пакетный режим использует образ API и работает с файлами, без БД. Это позволяет проверить сдачу без предварительной загрузки галереи в сервер. Общий модуль извлечения признаков сохраняет одинаковый препроцессинг в обоих режимах.

2. Методы и рабочая конфигурация

Признак

Путь обработки: bbox в пикселях исходного кадра → RGB → PIL bilinear, 208×208 → float32, диапазон 0...255, NCHW → **две модели на одном препроцессированном батче**: OSNet-AIN (OMZ 2022.1) и combined_v1 (наш дообученный OSNet-AIN) → L2-нормировка каждого сырого вектора 512 → покомпонентное среднее → L2-нормировка среднего → whitening $y = (x - m) @ P.T$ в float32 (матрица P и вектор m обучены на train_fit по дельтам ансамбля, $p=0,5$; обучение и проверка — [training/combined/](#)) → L2-нормировка с накоплением в float64, сохранение в float32. Порядок важен: среднее нормируется до whitening, потому что m обучена на нормированных входах. Внешняя ImageNet-нормировка не применяется: обе модели уже содержат нормировку входа. Основной образ требует CUDAExecutionProvider для обеих моделей; резервный образ явно выбирает CPUExecutionProvider. Формула признака и файлы весов одинаковы.

Происхождение **combined_v1**: LP-FT дообучение OSNet-AIN (обучение только классификатора при замороженном backbone → частичная разморозка; полная разморозка предусмотрена воротами, но в этом прогоне пропущена) на объединённом наборе RoundaboutHD (лицензия MIT) + CARLA (лицензия Apache-2.0) + train организатора. Полный журнал: [training/combined/journal.md](#), отчёт с метриками и бутстрэпом — [training/combined/REPORT.md](#). Беса model/osnet_ain_combined_v1.onnx входят в Git вместе с исходной OSNet и whitening (SHA-256 — §9). Фактический trainer, оркестратор, конфиги, export и whitening перенесены с узлов в [training/src/](#); там даны команды и границы подтверждённого происхождения.

Дельта от хранения whitening в float32 вместо float64-оригинала измерена отдельно: метрики валидации не меняются ни в одной из 16 печатных цифр, максимальное отличие эмбединга $1.43e-08$ (раздел 8).

Ранжирование и отказ

Пакетный режим по умолчанию выбирает для каждого запроса **50 ближайших по косинусу объектов галереи** и применяет k-reciprocal только к группе «текущий запрос + эти 50 объектов». Другие запросы test не читаются при ранжировании текущего. Для выбранных объектов оценка $s = 1 - d$ задаёт порядок; оставшиеся объекты идут ниже top-50 в косинусном порядке. Этот приём меняет только submission.csv, не embeddings.npy и не candidates.csv.

Рабочая строка конфигурации (29.09.2026): submission.csv: dl_j48, cosine top-50 → KR(k1=6, k2=3, $\lambda=0.3$) для каждого query отдельно; candidates.csv и HTTP API: cosine, t=0.5141976914190476. --no-rerank отключает KR только для submission.csv. Отказ в batch сравнивается с порогом по косинусу до округления confidence. Ранжирование и отказ получаются из одних и тех же эмбедингов в одном прогоне. REID_THRESHOLD_RERANK и старый порог 0.5282812306342437 оставлены для воспроизведения исторического общего KR, но в сдаваемом batch не применяются. Исполняемые параметры — [config.py](#); фактический режим и обе шкалы записываются в run_info.json.

HTTP API выполняет **точный косинусный поиск** Qdrant (exact=True), поэтому его порядок может отличаться от submission.csv. Переранжирование не зависит от других запросов в batch, но зависит от состава галереи. При равной оценке batch сохраняет порядок строк gallery-CSV. Близость не является вероятностью.

Порог задаётся --threshold для batch, полем threshold для API либо переменной REID_THRESHOLD внутри процесса. Переменная, заданная только в shell хоста, не передаётся контейнеру автоматически: для docker run нужен -e, для Compose — environment/override. API ограничивает выдачу параметром top_k (по умолчанию 10, максимум 100); candidates.csv содержит все пары, прошедшие косинусный порог. На другом наборе его F1/TNR не гарантированы.

3. Подготовка к сборке и установке

Нужны Linux x86_64, Docker Engine с Compose V2, shell, Python 3.10+ для проверки входов и curl. Для основного образа нужны NVIDIA GPU, драйвер и NVIDIA Container Toolkit; CPU-вариант работает без них. Для validation достаточно её изображений; для test/галереи сервиса нужны соответствующие test-CSV и изображения. CSV из Git недостаточно. Указанные команды запускаются из корня полученного репозитория.

Отдельной компиляции Python-кода и сборки frontend нет: браузер получает готовые HTML/CSS/JS, а Dockerfile устанавливает готовые Python wheels, копирует код и проверяет веса. Порядок установки: получить данные (шаг 1), проверить веса (шаг 2), импортировать базовые образы (шаг 3), выполнить [единую команду сборки и запуска](#). Установка Docker/Compose на хост и получение закрытого набора организатора этой командой не выполняются. Проверены Docker Engine **29.7.2** и Compose V2 **2.40.3**, а также Podman. Условия и результаты — [аудит Docker-пути](#) и [проверка команд](#).

Шаг 1. Пути и данные

```
export REPO="$(pwd -P)"
export DATA_DIR="$REPO/data"
export OUT_DIR="$REPO/outputs/reproduce"
export COMPOSE_FILE="$REPO/04-solution/service/docker-compose.yml"
mkdir -p "$OUT_DIR"
python3 04-solution/reproduce/check_inputs.py --mode val --data-dir "$DATA_DIR" \
  --report "$OUT_DIR/inputs-val.json"
```

Архив данных получают через личный кабинет [задачи № 7](#). Полный архив распаковывают непосредственно в DATA_DIR: images/, train.csv, test_query.csv, test_gallery.csv, README.md. Минимальные независимые наборы validation/test, способ получения для жюри и диагностика нехватки файлов — §7 и [reproduce/README.md](#). Проверенного прямого URL архива, его SHA-256 и отдельной лицензии в поставке нет. Отпечатки распакованного набора приведены в разделе 9.

Шаг 2. Веса

```
(cd "$REPO/04-solution/service" && sh model/fetch_model.sh)
```

Скрипт проверяет по полному SHA-256 все три сдаваемых файла весов и скачивает по прямой ссылке OMZ только то, чего нет рядом (OSNet). После него файлы находятся в 04-solution/service/model/. При несовпадении любого хеша сборку не продолжать. Оба ONNX и whitening отслеживаются Git. Исключение !04-solution/service/model/*.onnx в .gitignore включает эти ONNX вопреки общему *.onnx. В полном клоне скачивание не требуется.

Шаг 3. Образы и зависимости

Основной [Dockerfile](#) собирает GPU-образ на базе python:3.13-slim. Сборка скачивает из PyPI закреплённые версии ONNX Runtime GPU 1.20.2, CUDA 12.2 и cuDNN 9; при запуске они уже находятся внутри образа. [Ответ организаторов, вопрос 39](#) разрешает доступ к сети во время docker build и запрещает его во время инференса. CUDA-библиотеки не входят в Git; все три файла весов входят.

Для воспроизведения опубликованного CPU-прогона и сборки резервного [Dockerfile.cpu](#) используйте архивы из Git. Из корня репозитория:

```
(cd 04-solution/service/offline && sha256sum -c SHA256SUMS)
docker load -i 04-solution/service/offline/python-3.13-slim.tar.gz
docker load -i 04-solution/service/offline/qdrant-v1.15.5.tar.gz
```

После импорта CPU-образ собирают командой ниже. Сетевой docker pull python:3.13-slim может получить другую ревизию плавающего тега и потому не заменяет импорт проверенного архива при воспроизведении опубликованных версий.

CPU-образ собирается офлайн, из репозитория. Каталог [wheels/](#) содержит 30 файлов .whl, 59 146 237 байт: семь прямых зависимостей и их транзитивные версии. Колёс 30, а строк в разделе 10 — 31: pip приходит из базового образа. Колёса получены pip download -r requirements.txt -c requirements-lock.txt в том же python:3.13-slim; пересборка описана в [wheels/README.md](#). Dockerfile.cpu по умолчанию устанавливает их через --no-index --find-links=wheels. Исторические проверки офлайн-сборки ниже относятся именно к CPU-образу.

Для CPU-варианта нужны два базовых образа: python:3.13-slim для сборки и qdrant/qdrant:v1.15.5 для хранилища. Оба поставляются в [offline/](#) — отдельным архивом каждый, 45,6 и 65,4 МБ, загрузка командой docker load -i. Архив, положенный 21.09 одним файлом, содержал только Python с двумя тегами (podman save без --multi-image-archive молча теряет второй образ); 22.09 образы разложены по отдельным архивам и проверены загрузкой в отдельное хранилище — встают оба, с правильными идентификаторами и размерами.

--network none изолирует только шаги RUN. Внешний процесс сборки может обращаться к реестру. В [аудите 21.09](#) проверен **Podman 5.8.1**, с локальным Python base, --pull=never и дополнительным unshare --net вокруг процесса сборки. Команда после импорта base:

```
podman image exists docker.io/library/python:3.13-slim
podman build --no-cache --pull=never --network none \
```

```
-f "$REPO/04-solution/service/Dockerfile.cpu" \  
-t vehicle-reid-service-cpu "$REPO/04-solution/service"
```

Без base Podman останавливается на `image not known`; с ним офлайн-сборка прошла, freeze совпал с lock. **У `docker build --pull` — булев флаг**, `--pull=never` ему передавать нельзя ([Docker reference](#)). Для Docker заранее импортируйте base в хранилище выбранного builder, отключите внешнюю сеть у **Docker daemon / BuildKit**, затем выполните:

```
docker image inspect python:3.13-slim >/dev/null  
docker build --no-cache --pull=false --network none \  
-f "$REPO/04-solution/service/Dockerfile.cpu" \  
-t vehicle-reid-service-cpu "$REPO/04-solution/service"
```

`--pull=false` сам по себе не запрещает получение отсутствующего base. Отключение сети только у CLI, обращающегося к daemon, тоже недостаточно. Docker-вариант и Compose V2 проверены отдельным прогоном на Engine 29.7.2 / Compose 2.40.3 ([отчёт](#)).

Запасной путь для CPU-образа — ставить из сети: при отсутствии каталога сначала `mkdir -p "$REPO/04-solution/service/wheels"`, затем `docker build -f "$REPO/04-solution/service/Dockerfile.cpu" --build-arg PIP_SOURCE=network -t vehicle-reid-service-cpu "$REPO/04-solution/service"`. Он нужен, если колёса разошлись с `requirements.txt` или требуется другая платформа. Сам каталог `wheels/` нужен в любом случае: `COPY wheels/` в `Dockerfile.cpu` общий для обеих ветвей.

В итоговые образы колёса **не попадают**: зависимости ставятся в отдельной стадии сборки. Веса копируются внутрь обоих образов и проверяются при сборке, затем при загрузке модели. CPU-зависимости закреплены в [requirements-lock.txt](#), GPU-зависимости — в [requirements-gpu-lock.txt](#). Хеши Python wheel в этих `constraints`-файлах не закреплены; хеши трёх файлов весов проверяются. Тег базового образа `python:3.13-slim` плавающий (digest проверенной CPU-среды указан в разделе 10).

Замечание для хостов с SELinux (Fedora, RHEL, CentOS Stream и подобные)

Это касается **четырёх** команд ниже — всех, которые монтируют каталоги хоста: пакетный прогон (раздел 4), команды **T** и **R** (раздел 7), калибровка порога (раздел 8). Docker на таком хосте обычно расставляет метки сам; Podman — нет, и контейнер получает отказ в доступе к смонтированным каталогам. Проверенное решение — добавить в каждую такую команду `--security-opt label=disable`; альтернатива — суффикс `:z/Z` у каждого `-v`.

Добавьте флаг до первого запуска, а не после отказа. `app.batch` пишет все три файла **в самом конце**, поэтому `PermissionError: [Errno 13] Permission denied: '/out/embeddings.npy'` приходит после выполненного инференса — весь расчёт придётся повторить. В прежнем CPU-прогоне это заняло 5,5 минуты; время GPU-прогона не измерено. Команда **T** падает быстро, но с сообщением не по делу: `ModuleNotFoundError: No module named 'test_protocols'` — файл на месте, просто каталог `/repo` не читается.

4. Запуск и офлайн-поставка

Сборка, установка зависимостей и запуск — одна команда

После подготовки данных, **из корня репозитория** на хосте с NVIDIA GPU и NVIDIA Container Toolkit:

```
docker compose -f 04-solution/service/docker-compose.yml up --build -d
```

--build собирает основной GPU-образ по Dockerfile и устанавливает закреплённые зависимости из PyPI; Compose предоставляет GPU контейнерам api и loader, запускает Qdrant и однократную загрузку галереи. Данные по умолчанию берутся из data/ в корне. Для другого расположения перед командой задайте DATA_DIR=/абсолютный/путь/к/data. Назначение флагов сверено с [Docker Compose reference](#).

Это полная команда сборки и старта приложения при подготовленных входах. Сеть во время сборки разрешена ответом организаторов, но контейнеру она не нужна для формирования признака. Фактический провайдер проверяйте по GET /api/version: обе сессии должны показывать CUDAExecutionProvider первым. Реальное время на RTX A5000 здесь не заявляется без замера на стенде. На SELinux требуется доступ контейнеров к bind-mount данных; текущий Compose не задаёт :z/:Z, поэтому добавьте метки или настройте тома (\$3). -d возвращает управление до окончания загрузки галереи: готовность проверяют по выходу loader с кодом 0 и строке с числом загруженных объектов, как описано ниже. localhost:8000 после запуска — локальный адрес, а не опубликованная ссылка для жюри.

Без NVIDIA используйте резервный CPU-образ:

```
docker compose -f 04-solution/service/docker-compose.cpu.yml up --build -d --pull never
```

CPU-вариант собирается из Dockerfile.cpu и локальных wheels. Полный прогон именно этого пути на Docker Engine 29.7.2 / Compose V2 2.40.3 выполнен 22.09 ([отчёт](#)); он не является измерением на стенде организаторов.

Сервис с загруженной галереей — одна команда

Если GPU-образ vehicle-reid-service уже собран предыдущей командой либо импортирован из runtime-архива, повторный запуск без сборки (переменная COMPOSE_FILE задана в шаге 1 раздела 3):

```
docker compose up -d --no-build --pull never
```

Для CPU-образа явно укажите его Compose-файл:

```
docker compose -f 04-solution/service/docker-compose.cpu.yml up -d --no-build --pull never
```

Интерфейс: <http://localhost:8000/>. Swagger: <http://localhost:8000/docs>. OpenAPI: <http://localhost:8000/openapi.json>. Статические файлы Swagger поставляются локально. Загрузчик читает \$DATA_DIR/test_gallery.csv и **пересоздаёт** коллекцию; повторный запуск заменяет её прежнее содержимое. Дождитесь завершения loader и проверьте:

```
curl --fail http://localhost:8000/api/health
curl --fail http://localhost:8000/api/version
```

В health должны быть storage.reachable=true и непустое storage.gallery_points. Отдельное поле status="ok" само по себе не означает готовность галереи. До загрузки поиск возвращает HTTP 409 ({ "detail": "галерея не загружена — выполните app.load_gallery" }), при недоступной БД — 503. Оба ответа проверены.

gallery_points не доказывает, что отработала именно ваша загрузка. Том Qdrant именованный (qdrant_storage), а имя проекта Compose берётся из имени каталога с docker-compose.yml — это всегда service, одинаково у рабочего дерева и у любого клона. Поэтому up на машине, где сервис уже когда-то поднимали, видит **прежний** том: health отдаёт gallery_points=750 ещё до того, как ваш загрузчик дошёл до первого кадра. Так и случилось при сквозной проверке из чистого клона.

Достоверный признак — **завершение самого загрузчика**, а не содержимое хранилища:

```
docker compose logs --no-log-prefix loader | tail -1
# {"collection": "gallery", "points": 750, "rows": 750}
```

Эту строку `app.load_gallery` печатает последним действием — после `upsert` и проверки `points == rows`; до неё процесс не завершается, а при несовпадении падает. Нет строки — загрузка не дошла до конца, чем бы ни отвечал `health`. Проверено и под `podman-compose`: вывод тот же. Код выхода контейнера виден в `docker compose ps -a loader` (столбец `State` — `exited (0)`).

Запуск с заведомо пустым хранилищем (нужен, если прежний том мог остаться от другого прогона):

```
docker compose down -v          # удаляет контейнеры И именованный том проекта
docker compose up -d --no-build --pull never
```

Проверено на чистом томе: `gallery_points` равен `null` всё время работы загрузчика и становится 750 сразу после его выхода; загрузка 750 объектов заняла 64,5 с. Если удалять чужой том нежелательно, дайте прогону собственное имя проекта — `docker compose -p reid-check up -d ...`, тогда создаётся отдельный том `reid-check_qdrant_storage`, а `docker compose -p reid-check down -v` убирает за собой только его.

Загрузка галереи входит в `up: loader` — обычный разовый сервис Compose (профиля `tools` больше нет), он стартует после `healthcheck Qdrant`, отработывает и выходит. Готовность Qdrant проверяется `healthcheck`-запросом `/readyz` (в образе нет `curl`, поэтому проверка идёт через `/dev/tcp bash`), а `api` и `loader` объявлены зависимыми с `condition: service_healthy`. Дополнительно сам загрузчик ждёт доступности хранилища до извлечения векторов (`--wait`, по умолчанию 120 с) — это нужно для сред, где ожидание `healthcheck` не выполняется (поведение зависит от версии и стенда; `podman-compose 1.6.0` в отдельном `storage` аудита ожидал `healthcheck`, но его `systemd` unit не видел это `storage`). Повторная загрузка на другом каталоге данных: `DATA_DIR=/путь/к/данные docker compose run --rm loader` — эта форма блокирует терминал до конца загрузки и печатает ту же итоговую строку, то есть тоже годится как признак готовности.

`docker compose up -d` возвращает управление, пока загрузчик ещё работает. Замер 64,5 с выше относится к исторической CPU-проверке; для текущего ансамбля `d1_j48` время зависит от устройства и нагрузки, GPU-вариант не измерен. До конца загрузки поиск отвечает 409 — это ожидаемо, а не отказ сервиса.

Пакетный инференс — одна команда, сеть отключена

```
docker run --rm --gpus all --network none \
-v "$DATA_DIR:/data:ro" -v "$OUT_DIR:/out" \
vehicle-reid-service python -m app.batch \
--images-dir /data/images --query /data/test_query.csv \
--gallery /data/test_gallery.csv --out-dir /out --threads 2
```

Для закрытого теста заменяются только входной каталог и CSV. Метки `vehicle_id` и `camera_id` инференсу не нужны. Выходной каталог должен быть доступен на запись. `--gpus all` предоставляет контейнеру NVIDIA-устройство; основной образ требует активного CUDA-провайдера. Для CPU-варианта уберите этот флаг, используйте `vehicle-reid-service-cpu`. **На хосте с SELinux добавьте `--security-opt label=disable`** — см. замечание в конце раздела 3.

Отдельный [измеритель полного извлечения](#) выполняет 50 прогревов, 300 замеров batch-1 с CUDA-синхронизацией и не менее 10 секунд для каждого batch 1/8/16/32. Он включает чтение JPEG, bbox, препроцессинг и обе ONNX-модели, но исключает поиск; результаты на GPU организаторов пока не получены.

Передача на машину без интернета

На машине сборки сохраните **оба** образа:

```
docker save -o "$OUT_DIR/runtime-images.tar" vehicle-reid-service docker.io/qdrant/qdrant:v1.15.5
sha256sum "$OUT_DIR/runtime-images.tar" > "$OUT_DIR/runtime-images.tar.sha256"
```

Podman вместо Docker: для нескольких образов используйте `podman save --multi-image-archive`. Без этого флага Podman 5.8.2 в [проверке CPU-комплекта](#) сохранил только один образ; размеры того архива не относятся к новому GPU-образу. Передайте архив образов и разрешённый комплект данных организатора отдельно от Git. На целевой машине выполните `docker load -i /путь/к/runtime-images.tar`; для batch достаточно образа сервиса и данных, без Qdrant. Если GPU-образ уже собран и перенесён, инференс выполняется с `--gpus all --network none`. Офлайн-архивы базовых образов и Python wheels в репозитории предназначены для CPU-резерва; CUDA-библиотеки уже находятся в собранном GPU-образе.

5. Формат сдаваемых файлов

Схема основана на README.md архива организатора, а не только на общих формулировках ТЗ.

Первичные требования: [ТЗ §8](#), стр. 5 PDF, и раздел «Как сдавать решение → Артефакты в репозитории» выданного data/README.md (SHA-256 b517186daf5186f8ace0b3d2feb9fbce328cd09e620f22b84ff9a2a292d4575c). Этот README входит в архив данных, но не в Git; его точная схема раскрыта ниже. В ТЗ число строк определяется входными CSV: 1110/750 — размеры данного выданного набора, а не требование ко всякому закрытому тесту.

Файл	Содержимое
submission.csv	Без заголовка: query_id,gallery_id_1,...,gallery_id_10; строки query в порядке входного CSV, кандидаты по убыванию оценки; десять значений только при N_gallery >= 10
embeddings.npy	float32, (N_query + N_gallery, 512); сначала все query, затем все gallery, порядок внутри блоков как в CSV
candidates.csv	С заголовком query_id,gallery_id,confidence; все пары с косинусом $s \geq t_{\cos}$, без лимита десятью; уверенность записана с шестью знаками после точки; отсутствие строк означает отказ при уникальных query ID и успешном прогоне
run_info.json	Служебный протокол: модель, хеш, версии, косинусный порог отказа, шкала ранжирования, top-50, размеры, счётчики, время

Переранжирование меняет **только** submission.csv. Векторы и косинусный отказ не меняются. Старые файлы [baseline/artifacts](#) и выпуск от 21.09 в истории Git не служат эталоном нового независимого ранжирования. Текущий [комплект от 29.09](#) имеет [manifest.json](#) с SHA-256, входами, image ID и параметрами; проверка — `sha256sum -c SHA256SUMS` в каталоге выпуска. У выданного test 1110 query и 750 gallery: матрица (1860, 512), 48 отказов по косинусному порогу.

Детали сериализации и границы требований. Оба CSV выпуска используют запятую, ASCII-совместимый UTF-8 без BOM и окончания строк CRLF. Идентификаторы сохраняются строками из входных CSV. Официальные `evaluate.py` и `example_submission.zip` требуют **без заголовка** для `submission.csv` и **с заголовком** для `candidates.csv`; отказ — отсутствие строк запроса во втором файле. `float32`, 512, L2-нормировка и разные шкалы ранжирования / отказа — выбранные свойства нашего решения.

Топ-10 обязателен только в `submission.csv`: при `N_gallery >= 10` все запросы, включая отказные, имеют десять кандидатов. При меньшей непустой галерее строки имеют менее одиннадцати полей — это ограничение формата (F2 ниже). В `candidates.csv` ограничение десятью в первичных материалах не задано: записываются все принятые пары. Пустой ответ реализован отсутствием строк данного `query_id`; строки `query_id, , NaN` или `-1` не добавляются. Эта конвенция прямо указана в официальном `evaluate.py`. При чтении нужно проверить код завершения `batch` и соединить результат со **всеми** `query` из входного CSV; это восстанавливает отказы только при уникальном `image_id` в `query`. Разные `bbox` с одним ID по выходному CSV не различить (F4 ниже). Сравнение с порогом выполняется **до** округления `confidence` до шести знаков; повторная фильтрация по записанному `confidence` может изменить решение (F6).

Известные границы поведения

Эти ограничения относятся к `app.batch` текущего выпуска `d1_j48`. Они подтверждены [аудитом формата](#) и [проверкой исправлений F1/F5](#). Численный профиль и порядок объектов дополнительно проверены [независимым критиком границ](#). Ниже — оставленные границы, а не заявленные исправления.

- **F2 — галерея меньше десяти объектов.** При одном объекте строки `submission.csv` содержат два поля вместо одиннадцати; `batch` завершается с кодом 0. Вообще при `1 <= N_gallery < 10` пустые позиции не дополняются. Исправление отложено до согласования заполнителя с организатором: формат недостающих ID не определён. Для прямоугольного `submission` нужны минимум десять строк галереи; код 0 сам по себе не гарантирует эту схему.
- **F3 — пустая галерея.** При непустом `query` и `N_gallery = 0` `batch` завершается с кодом 1, новых файлов нет; продуктовый ответ «совпадений нет» не формируется. Пустой `query` также не поддержан. Обработка оставлена до согласования формата пустого комплекта. Перед запуском нужны непустые CSV; проверяйте код возврата, поскольку прежние файлы в `out-dir` могут остаться.
- **F4 — повторяющиеся `image_id`.** Разные `bbox` одного `query` имеют одинаковый ключ результата: `join` неоднозначен, отказ одного `bbox` может скрыться за принятым совпадением другого. Дубликаты `gallery` повторяют ID в `топе` и пары в `candidates.csv`. Исправление требует согласованного идентификатора объекта вместо одного ID кадра; схему выпуска не меняем. Для однозначной выдачи обеспечьте уникальность `image_id` отдельно в `query` и `gallery` до запуска: сам `batch` её не проверяет.
- **F6 — округление `confidence`.** Пара принимается по исходному `s >= t`, затем `s` записывается с шестью знаками. На границе записанное значение может оказаться ниже полного порога. Точность CSV оставлена прежней, чтобы сохранить формат выпуска и решение по неокруглённой оценке. Наличие пары в `candidates.csv` означает принятие; не фильтруйте её повторно по округлённому `confidence`.
- **F7 — больше десяти принятых пар.** `candidates.csv` содержит все пары, прошедшие порог; в аудите при явном `--threshold 0` и галерее из 15 объектов получено 15 на запрос (при штатном пороге на том же наборе — 3 и 0). Усечение не добавлено: первичные требования задают десять только для `submission.csv`. Читатель `candidates.csv` должен поддерживать произвольное число принятых строк; для первых десяти используется `submission.csv` независимо от отказа.

• **Исторический F1/F10 — отказ точной копии в прежнем общем KR.** Число 0.43999999999999984 (около 0.44) воспроизведено на синтетическом наборе форматного аудита **37 query × 37 gallery**, с исходным порядком строк, кодами и bbox. Это не 37 реальных автомобилей организатора. Профиль: d1_j48, --batch 32 --threads 2, KR (6, 3, 0.3), OPENBLAS_NUM_THREADS=1 OMP_NUM_THREADS=1 MKL_NUM_THREADS=1, Python 3.13.15, NumPy 2.5.3, Pillow 12.3.0, ONNX Runtime 1.30.0, worker-vm, runtime-образ localhost/job72-jury:6179b69. Строки с индексами **0, 3, 5, 12** (rgb.jpg, progressive.jpg, exif_1.jpg, exif_8.jpg, bbox (0, 0, 128, 96)) имеют побайтно равные query/gallery-векторы, но self-score = best = 0.43999999999999984; прежний порог 0.5282812306342437 отклонял **4/37** запросов. На том же наборе --no-rerank даёт **0/37** отказов. При изменении только BLAS/OMP/MKL с 1 на 2 потока тот же KR также дал **0/37** отказов: отличия компонентов эмбедингов до 5.21540641784668e-08 изменили решение. На свежих векторах профиля 1 все 20 проверенных перестановок только gallery меняли scores (максимум |Δscore| = 0.56, до 105 решений по парам и четырёх отказов запросов). Это численная проверка rerank на уже вычисленных векторах, а не 20 дополнительных инференсов. Этот опыт относится к оставленному в коде исследовательскому rerank_scores на объединении всех query и gallery, **не к сдаваемому rerank_scores_independent и не к косинусному отказу**. Его входы, SHA и команды приведены в отчёте критика выше. Для текущего режима отдельная проверка точной копии нужна при оценке другой галереи; F1/TNR большого сплита на малый набор не переносятся.

6. Протокол метрик и достигнутые значения

Валидация находится в [split/files](#): 1110 запросов, 750 объектов галереи. У 832 запросов есть кросс-камерная пара, у 278 пары нет. Идентичности train_fit отделены от валидации. SHA-256 CSV закреплены в [manifest.json](#).

Ранжирование оценивается с camera_policy="market": из галереи запроса удаляются объекты **той же идентичности и той же камеры**. Другие автомобили с той же камеры остаются отрицательными кандидатами. ТЗ допускает и трактовку «удалить всю камеру»; она реализована как all_same_camera, но приведённые числа относятся к market.

Опубликованный организаторами evaluate.py оценивает **mAP@10 по submission.csv** как основную метрику ранжирования (45% оценки). Он исключает из ответа пары с тем же vehicle_id и camera_id, затем берёт до десяти оставшихся позиций. AP@10 делится на min(n_pos, 10), где n_pos — число допустимых позитивов в галерее. Запросы без пары исключаются из mAP/Rank и проверяются в отказе. Те же эмбединги с полным ранжированием из embeddings.npy оцениваются **отдельно**, только диагностически. Уточнение о независимости каждого запроса, формате отказа и метриках опубликовано в [ответах организаторов](#).

Ранжирование submission.csv на val	mAP@10	Rank-1	Rank-5
d1_j48, независимый top-50 KR (сдаваемый)	0.7411030506	0.7079326923	0.8605769231
d1_j48, cosine (--no-rerank)	0.7242262382	0.6850961538	0.8822115385

Это прогон официального evaluate.py на **том же многократно использованном validation-сплите** 1110×750, из них 832 запроса в зачёте. Разница mAP@10 с cosine равна +0.0168768124; Rank-5 у top-50 KR ниже, чем у cosine. Отдельный диагностический расчёт организатора по embeddings.npy даёт full-ranking mAP **0.7316093422** и mINP **0.6928460434** — он не описывает порядок submission.csv. Результат закрытого теста неизвестен: его CSV не содержат меток личности и камер. Хеши входов, выходных файлов и точные числа этого запуска записаны в [протоколе официальной валидации](#).

Прежний исследовательский режим объединял **все query и gallery** перед KR. Он дал full-ranking mAP 0.7740915539, Rank-1 0.7307692308 и прежнее локальное mAP@10 0.7684546226 ([источник](#)). Эти воспроизведённые числа не являются оценкой сдаваемого независимого ранжирования: общий режим использует другие test-query как контекст, что запрещено ответом организаторов. Его сохраняем как исторический эксперимент, а не как заявленную метрику сдачи.

В историческом общем KR при смене модели 20.09.2026 mAP / Rank-1 выросли с 0.6937 / 0.6635 у OSNet+KR до 0.7741 / 0.7308 у d1_j48. По сравнению с прежним лучшим кандидатом d1 прирост mAP составил +0.0120: это меньше заранее заданной приёмочной $\sigma(\text{mAP}) = 0.0134$, поэтому по этому правилу он не засчитывается. Парный бутстрэп дал CI95 [+0.0040, +0.0205], $p = 0.003$ (4000 повторов); команда выбрала d1_j48 с учётом этого результата. Полное [сравнение кандидатов](#) сохраняет исходный критерий. Разрыв по камере у d1_j48 составляет +0.1103 против +0.1144 у d1 и +0.1417 у исходной OSNet. В абляции области номера её маскирование не показало эффекта, отличимого от контрольной зоны той же площади.

Обоснование порога

В сдаваемом candidates.csv единица решения — **запрос**. Если хотя бы одна косинусная оценка $s \geq 0.5141976914190476$, файл содержит все прошедшие порог пары; отсутствие строк данного query_id означает отказ. Порог сравнивают с полным значением до записи шести знаков после точки. Это та же шкала, что в HTTP API, но не шкала KR в submission.csv.

Порог был выбран 20.09 на validation-сплите по заранее заданному компромиссу между отказами и полнотой. В исходной калибровке положительный класс — наличие межкамерной пары, режим market + presence: максимизируется $\min(\text{TNR}, F1_{0.10}, F1_{0.25}, F1_{0.40})$. Индекс p означает предполагаемую долю запросов без пары, а $F1_p = 2(1-p)r / ((1-p)(1+r)+pf)$, где r — recall и f — доля ложных принятий. $\text{TNR} = 1-f$. При равенстве берётся больший F1, затем больший TNR. Значение и правило можно пересчитать через [калибровку](#) и [calibrate_threshold.py](#).

Официальная проверка отказа отличается от исходной калибровки. evaluate.py проверяет, есть ли у запроса допустимая межкамерная пара, а принятый ответ считает верным, когда *верхний* кандидат имеет тот же vehicle_id; при подсчёте correctness верхнего кандидата его камера не отбрасывается. На уже использованной валидации текущие косинусные candidates.csv дали TP/FP/FN/TN **803/84/20/203**, F1 **0.9391812865**, TNR **0.7302158273**, PR-AUC **0.9926129189**. Это не независимая оценка и не прогноз закрытого теста. Порог после публикации официального скрипта не подбирался заново по той же валидации.

Для сравнения, первоначальный исследовательский market + presence оценщик дал при том же косинусном пороге F1 **0.7684996606** и TNR **0.7302158273**. Исторический общий KR с собственным порогом 0.5282812306342437 дал F1 **0.8090787717** и TNR **0.7841726619**; он **не используется** для сдаваемого отказа. Числа нельзя смешивать: у двух оценщиков различается смысл верного принятия, а у KR ещё и шкала оценки. Старые таблицы и полный перебор сохранены в [отчёте калибровки](#) и [контуре воспроизведения](#).

Другой состав галереи и запросов меняет F1/TNR. В закрытых test-CSV нет vehicle_id и camera_id; правильность отказов по ним пока неизвестна.

7. Как повторить наши числа

В Git есть код, веса и CSV сплита, **но нет изображений организатора**. Validation-R требует ровно **1860 исходных JPG** по image_id из 04-solution/split/files/val_query.csv (1110) и val_gallery.csv (750). Список **каждого имени, размера и SHA-256** — [reproduce/inputs-manifest.json](#), ключ data.val;

отпечатки CSV — `repo_files` и [split/files/manifest.json](#). Test-R отдельно требует `test_query.csv`, `test_gallery.csv` и 1860 других кадров (`data.test` того же `manifest`). Отсутствие `test` не препятствует `validation`.

Участник получает исходный набор через личный кабинет [задачи №7](#). Жюри использует **тот же выданный участникам набор** из своих материалов либо получает его у постановщика. Отдельного проверенного канала выдачи жюри и публичного прямого URL архива у нас нет. Если кабинет недоступен, данные нужно запросить у организатора; из этого репозитория восстановить изображения нельзя. Изображения не публикуются в Git. Закрытый тест жюри не является данным `validation`-сплитом и не воспроизводит наши `validation`-числа.

```
$REPO/04-solution/split/files/{val_query,val_gallery,train_fit,split_assignment}.csv
$DATA_DIR/
  images/<image_id>.jpg      # имена из manifest, без дополнительной папки images/images
  test_query.csv             # только для R-test / R-all
  test_gallery.csv           # только для R-test / R-all
  train.csv, README.md      # для подготовки обучения; R-val их не требует
```

SHA-256 `test_query.csv` — `97e1ed21942bae9c95b1ce2e5d339d9f635bf49fa484367e6b19349789bb9b4c`,
`test_gallery.csv` — `a64ed21fa39bbfd8c7a172468d043415800500b6ed695cdb8162188cf9005496`. Полный исходный набор и агрегированный отпечаток изображений — §9.

Сначала проверить входы

На хосте достаточно Python 3.10+, без NumPy/torch/ONNX Runtime:

```
python3 04-solution/reproduce/check_inputs.py --mode val --data-dir "$DATA_DIR" \
--report "$OUT_DIR/inputs-val.json"
```

Проверяются **все** нужные файлы, размеры и SHA-256. При нехватке данных — `exit 2`, число отсутствующих файлов, примеры имён и каталог назначения; полный список записывается в JSON. Инференс не начинается. Для `test` замените `val` на `test`. Эта же проверка встроена в каждую команду R ниже; флаг `--check-only` запускает только её. Подробнее — [README контура](#).

R-val: исторический контур валидации и калибровки

После сборки CPU-образа `vehicle-reid-service-cpu` из §3-4, из корня репозитория:

```
docker run --rm --network none --cpus 2 --memory 4g \
-e OPENBLAS_NUM_THREADS=1 -e OMP_NUM_THREADS=1 -e PYTHONDONTWRITEBYTECODE=1 \
-v "$REPO:/repo:ro" -v "$DATA_DIR:/data:ro" -v "$OUT_DIR:/out" \
vehicle-reid-service-cpu python -B /repo/04-solution/reproduce/run.py \
--mode val --data-dir /data --out-dir /out
```

На SELinux добавьте `--security-opt label=disable` (§3). Скрипт использует исходники из смонтированного репозитория и зависимости образа; модели проверяет неизменённый Embedder. Переопределения `REID_*` для эталонного прогона запрещены. Он заново извлекает признаки, вызывает первоначальный исследовательский контур метрик и правило выбора порогов, проверяет порядок векторов отдельным инференсом граничных строк. Готовые `.npy` ему не нужны. Выход: `val/`, `inputs-val.json`, `metrics.json`. Поля и арифметика `validation` сохранены из прежней команды R; допуск для `mAP`, `Rank-1/5` и обоих порогов — `1e-6`. **Эти якоря проверяют исторический общий KR, а не результат текущего submission.csv.** `F1/TNR` здесь рассчитаны в `market + presence`, поэтому отличаются от официального `candidates.csv`.

Ожидаемые основные строки (последние цифры порога зависят от CPU/потоков):

```
cosine: mAP 0.7316093422310448, Rank-1 0.6850961538461539,  
        threshold ≈ 0.5141976914190476, F1 0.7684996605566871, TNR 0.7302158273381295  
rerank: mAP 0.7740915539438481, Rank-1 0.7307692307692307,  
        threshold ≈ 0.5282812306342437, F1 0.8090787716955942, TNR 0.7841726618705036
```

Источник исторических эталонов: [s02_metrics.json](#) и [calib-d1_j48/](#). R не восстанавливает камерные эксперименты, абляции и bootstrap всех исследовательских отчётов (§8, §11).

Официальный evaluate.py: текущие файлы и mAP@10

Организаторы добавили в обновлённый архив данных evaluate.py и example_submission.zip. Их локально проверенные SHA-256:

```
evaluate.py          655c71db8c2e4d2cd7680c40c768afacfdffff360401111c1a46df921551ffa3  
example_submission.zip cccda5bf0c801be8fd5748646dac345f180f6d11988ecbf4ec17ac9c311e4f46
```

В Git эти файлы организатора не дублируются: получите их через личный кабинет задачи. На размеченных val_query.csv и val_gallery.csv соберите временный gt_val.csv со столбцами image_id, vehicle_id, camera_id, split, где split равен query или gallery соответственно. Это преобразование не меняет метки. Например, из корня репозитория после R-val:

```
python3 - "$OUT_DIR/gt_val.csv" <<'PY'  
import csv, sys  
from pathlib import Path  
with open(sys.argv[1], 'w', newline='') as dst:  
    writer = csv.writer(dst)  
    writer.writerow(('image_id', 'vehicle_id', 'camera_id', 'split'))  
    for split in ('query', 'gallery'):  
        path = Path('04-solution/split/files') / f'val_{split}.csv'  
        with path.open(newline='') as src:  
            for row in csv.DictReader(src):  
                writer.writerow((row['image_id'], row['vehicle_id'],  
                                row['camera_id'], split))  
PY
```

R-val уже запустил сдаваемый app.batch на этих CSV и validation-изображениях. Теперь запустите официальный оценщик:

```
export OFFICIAL_EVALUATOR=/путь/к/evaluate.py  
python "$OFFICIAL_EVALUATOR" --gt "$OUT_DIR/gt_val.csv" \  
--submission "$OUT_DIR/val/submission.csv" \  
--candidates "$OUT_DIR/val/candidates.csv" \  
--embeddings "$OUT_DIR/val/embeddings.npy" \  
--query 04-solution/split/files/val_query.csv \  
--gallery 04-solution/split/files/val_gallery.csv \  
--json "$OUT_DIR/official-val.json"
```

Для данной команды нужны numpy и pandas; проверка SHA файла оценщика перед запуском — sha256sum "\$OFFICIAL_EVALUATOR". Ожидаемые **локальные** результаты текущего релиза: mAP@10 0.7411030506, Rank-1 0.7079326923, Rank-5 0.8605769231, F1 0.9391812865, TNR 0.7302158273. Без файла организатора этот конкретный прогон официальной метрики не воспроизводится; старый metrics.json не заменяет его. Закрытый test не имеет доступного нам GT.

R-test: только сдаваемые файлы выданного теста

```
docker run --rm --network none --cpus 2 --memory 4g \
-e OPENBLAS_NUM_THREADS=1 -e OMP_NUM_THREADS=1 -e PYTHONDONTWRITEBYTECODE=1 \
-v "$REPO:/repo:ro" -v "$DATA_DIR:/data:ro" -v "$OUT_DIR:/out" \
vehicle-reid-service-cpu python -B /repo/04-solution/reproduce/run.py \
--mode test --data-dir /data --out-dir /out
```

Выход: test/{submission.csv, embeddings.npy, candidates.csv, run_info.json}, inputs-test.json, test-report.json с хешами. Метрики качества test не считаются: его vehicle_id/camera_id не выданы. Manifest опубликованного выпуска — [artifacts-final/manifest.json](#). run_info.json содержит время, поэтому его хеш пересчёта будет другим. Для общего прежнего пути используется --mode all; он заранее требует обе части и пишет metrics.json с обеими batch-записями. Для произвольного закрытого теста используйте обычный app.batch из §4: manifest R-test намеренно фиксирует именно выданный участникам набор, а не любой набор того же размера.

T: тесты контура; V: версии

```
docker run --rm --network none -e PYTHONDONTWRITEBYTECODE=1 \
-v "$REPO:/repo:ro" -w /repo/04-solution/eval \
vehicle-reid-service-cpu python -B -m unittest -q test_metrics test_protocols
docker run --rm --network none vehicle-reid-service-cpu python -m pip freeze --all
```

Дополнительно [tools/calibrate_threshold.py](#) выполняет 187 сверок точек с контуром (§8); [tools/eval_split.py](#) оценивает уже извлечённые validation-векторы. Эти инструменты читаются из Git, Dockerfile не копирует их в образ.

8. Таблица «число → команда» и границы воспроизведения

Историческая проверка R-val 21.09.2026: на отдельном снимке тогдашних исходников, смонтированном read-only в сохранённый образ аудита job_72, из исходных 1860 JPG получены ровно исторические mAP/Rank-1/F1/TNR строки R-val из §7. В каталоге данных не было test-CSV и test-кадров. Оба порога пересчитаны с отклонением менее $1.1e-8$; 60 тестов метрик и 5 тестов ранней проверки входов прошли. [Протокол и полные результаты](#). Этот прогон не является новой сборкой, свежим Git-клоном или повтором полного Docker/Compose-стенда. Ниже исторические проверки отдельно отмечены датами. Отдельный R-test тоже прошёл: три сдаваемых файла совпали по SHA-256 с выпуском 21.09, run_info отличается только временем. Дополнительная калибровка через код сервиса на новых validation-векторах прошла 187 сверок, max_abs_error=0.0.

Числа/утверждение	Как получить	Результат проверки
1110 query, 750 gallery, 832 с парой, 278 без пары; размерность 512	R → split, batch, row_order	Пересчитано; SHA-256 сплита и разделение идентичностей проверены
Исторические full-query KR mAP/Rank и прирост 0.0424822117	R → base, reranked, delta_mAP	Совпали с s02_metrics.json ; допуск $1e-6$. Это исследовательский якорь, не метрика сдаваемого top-50 режима
Историческая калибровка обеих шкал и market + presence F1/TNR	R → calibration, rerank_calibration, base.refusal, rerank_refusal, old_threshold	Пересчитана старым evaluate() проекта и сверена с calib-d1_j48/ ; текущий batch использует только косинусный порог

Числа/утверждение	Как получить	Результат проверки
Сдаваемый независимый top-50 KR: mAP@10 0.7411030506, Rank-1 0.7079326923, Rank-5 0.8605769231; cosine отказ F1 0.9391812865 / TNR 0.7302158273	Эмбединги из validation-изображений, релизные serializers, затем evaluate.py организатора по команде \$7	Хеши всех входов и файлов — в протоколе . Требуется отдельно выданный оценщик с SHA-256 выше; тот же val использовался при разработке
Параметры (6,3,0.3) как оптимум подбора	Не команда, а историческая справка. Сетку считал s04_grid.py <label> <query.npy> <gallery.npy> <query_meta.csv> <gallery_meta.csv> — пять обязательных аргументов, без них ValueError на разборе argv. Векторов, которые он ждёт (04-solution/postproc/out/*.npy из s03_extract.py), в git нет: .gitignore исключает *.npy. Сохранён результат: grid_tune_base.json	Применение параметров проверено командой R; исходная сетка заново не воспроизведена из чистого git
8 836 743 байта и SHA-256 сдаваемого OSNet	R → model; sha256sum 04-solution/service/model/*.onnx	Скачано заново, размер и хеш совпали
Второй ONNX combined_v1: 8 742 779 байт, b1ba5021...02efb2; матрица whitening f32: 1 051 114 байт, eb4433ff...4b3c5b5; f64-оригинал матрицы: 2 101 738 байт, 4b02f158...267eb625	sha256sum 04-solution/service/model/osnet_ain_combined_v1.onnx 04-solution/service/model/lw_ens_j48_rho0.5.npz 04-solution/training/combined/lw_ens_j48_rho0.5_f64.npz	Совпали с config.py и проверкой в Dockerfile; f64-оригинал нужен только для пересчёта дельты f32
Дельта метрик от f32-хранения whitening	скрипт прогона job_55 (сравнение A f64 / B f32-хранение / C f32-сервис на одних векторах валидации)	d_kr_mAP = 0.0, d_cos_mAP = 0.0 (все 16 печатных цифр совпали); max Дэмбединг = 1.4282077284710759e-08
Порядок (query; gallery) в embeddings.npy	R → row_order, независимый batch=1 на границах	Проверено переизвлечением, а не чтением отчёта
60 тестов метрик	T	Пройдены (15-16.09), повторены 20.09 и 21.09; новый лог
187 прямых сверок новой калибровки (20.09)	docker run --rm --network none -v "\$REPO:/repo:ro" -v "\$OUT_DIR:/out" vehicle-reid-service-cpu python -B /repo/04-solution/service/tools/calibrate_threshold.py /out/val/embeddings.npy /out/calibration	Пройдены на независимо извлечённых векторах конфигурации d1_j48; результат — headline.json и verification.json
Точные версии всех пакетов образа	V	Полный freeze проверенной сборки — \$10
Исторические 43.8 мс/объект и 0.55 с на rerank	Не команда, а историческая справка. Замер делал s09_timing.py. Ему нужны исследовательское окружение (раздел 10), каталог изображений (REID_DATA_DIR) и промежуточные векторы 04-solution/postproc/out/*.npy из шага s03_extract.py; .npy в git не входят. Из чистого клона скрипт падает трейсбеком FileNotFoundError на первом же недостающем входе — запускать его не нужно. Сохранён результат: s09_timing.json	Точные исторические тайминги не воспроизведены. R выполняет новый ограниченный замер, с другим объёмом выборки и лимитом CPU

Числа/утверждение	Как получить	Результат проверки
Эффект зоны пластины около -0.003 mAP, 95% CI $[-0.011; +0.004]$; расширенная маска: верхняя граница $+0.016$	Не команда, а историческая справка. Считал eval_variants.py по векторам 13 вариантов из plate-ablation/work/emb/; их в git нет. Запущенный в исследовательском окружении (раздел 10), скрипт это и сообщает — понятным сообщением, а не трейсбеком: нет векторов вариантов в .../work/emb (13 из 13, например base)	Не воспроизведено из git: нет work/emb, детекций и исходной ручной разметки. Числа только из ablation.json и отчёта
Качество локализации пластины, bootstrap/crossfit и расширенные EDA-числа	Команды соответствующих plate , refusal , EDA отчётов	Полная цепочка не восстановлена; не включать в перечень независимо воспроизведённых результатов
Размеры, SHA-256 и версии внешних источников	sha256sum FILE, wc -c < FILE, V; manifest внешних eval-источников	Измерены для локальных файлов; неизвестные версии и хеши датасетов явно отмечены в §9

Про строки «историческая справка». Скрипты 04-solution/postproc/scripts/ и 04-solution/plate-ablation/scripts/ — рабочие записи исследования, а не часть сдаваемого пути; **запускать их для проверки решения не нужно.** Из чистого клона они и не отработают: в образ сервиса они не копируются, системный python3 даёт ModuleNotFoundError: No module named 'onnxruntime' (им нужно исследовательское окружение из раздела 10), а в этом окружении они упрутся в промежуточные входы, которых в git нет (*.npy, work/, каталог изображений). Проверено: eval_variants.py сообщает об этом понятной строкой, s09_timing.py и s04_grid.py — трейсбеком FileNotFoundError и ValueError соответственно. Всё, что из этих цепочек вошло в заявленные числа, сохранено рядом в out/*.json, а сдаваемые метрики пересчитывает R-val без этих исследовательских entry point и их кэшированных эмбедингов (библиотека common.rerank используется напрямую).

Скорость зависит от оборудования и его загрузки; значения R — справочный замер, не FPS стандартизованного скрипта жюри. Исторический общий KR использовал квадратичную память от Q+G; текущий top-50 KR ограничивает размер локальной матрицы 51 объектом на запрос, но всё ещё требует косинусного поиска по всей галерее и хранения её эмбедингов. Миллион объектов и стабильный real-time-поток не проверены.

9. Все использованные внешние модели, данные и исходники

Ниже раскрыты восемь известных источников данных, включая предобучение внешних моделей; семейство датасета не считается точной версией его архива. Для наших входов без номера релиза используются SHA-256 файлов/архивов. Это позволяет сравнить два полученных экземпляра, но не восстанавливает неизвестную ревизию upstream и не обеспечивает доступ к закрытым данным. Неизвестные версии явно помечены: требование о **всех** версиях пока закрыто не полностью. Библиотеки и окружения перечислены в §10.

Модели и веса

Назначение	Версия, источник и лицензия	Размер и SHA-256
Сдаваемый OSNet-AIN (модель 1 конвейера)	Open Model Zoo 2022.1 , vehicle-reid-0001. Прямой ONNX , карточка релиза 2022.1.0 . MIT для оригинальной модели, текст лицензии	8 836 743 байта (8.427 MiB; 8.837 MB). 4aaad3e5db648618b0df3d2ff21c61323985ff9e50194c3d2edd4fb87c92d91f

Назначение	Версия, источник и лицензия	Размер и SHA-256
Сдаваемый combined_v1 (модель 2 конвейера)	Наш дообученный OSNet-AIN: LP-FT на RoundaboutHD (MIT) + CARLA (Apache-2.0) + train организатора. Внешнего URL нет; журнал — training/combined/ . Поставляется в Git (!04-solution/service/model/*.onnx)	8 742 779 байт. b1ba5021275b34079a1653608bdfd215fc9404306dc909852e4cdfa03402efb2
Сдаваемая матрица whitening	Наш артефакт: P, m (p=0,5), обучены на train_fit по дельтам ансамбля; поставляется в float32, f64-оригинал — training/combined/lw_ens_j48_rho0.5_f64.npz	1 051 114 байт. eb4433fffd5e38d3751d5cb04e234090060a83be6d1720b47bcf2fa1274b3c5b5 (f64: 2 101 738 байт, 4b02f158fa54d89a54f9ad30d7e471f1baa14d7019ea9ea26b42ea7c267eb625)
Сравнение второй модели, в сервис не включено	FastReID SBS ResNet50-IBN, веса релиза v0.1.1 . Прямая загрузка, Model Zoo . Код Apache-2.0; отдельная лицензия checkpoint в исследовательском пакете не найдена	198 261 759 байт. 57fb9c17d88911ea64390bf5427f43511435e7f88f6eed9dbc969d4b611e53cd
Локальная производная предыдущего checkpoint	veri_sbs_R50-ibn.model_only.pth, сохранение ckpt["model"] скриптом s07_fastreid_extract.py ; отдельного внешнего URL нет	99 273 627 байт. 8595fa79eeb09f35c565729be1e8826e3b1de7951c86bff0aff048c78529076f

Весовой лимит ТЗ (≤ 2 ГБ) проверяется по сумме трёх сдаваемых файлов: $8\,836\,743 + 8\,742\,779 + 1\,051\,114 = \mathbf{18\,630\,636\,байт}$. Оба ONNX и матрица whitening входят в Git и проверяются по SHA-256 при сборке образа и при загрузке модели. FastReID использовался при исследовании, поэтому раскрыт, хотя в runtime не нужна. [Отчёт постобработки](#) объясняет отказ от ансамбля и ТТА на том этапе; итоговый ансамбль d1_j48 — [training/combined/REPORT.md](#).

Обучающие источники публичных весов

OSNet обучен не только на VeRi. Upstream [README.rst, commit ea27fd23c962addbd24d8586c5aaf8afe60db0db](#) перечисляет VeRi, VERI-Wild, CompCars и VMRRdb. В [папке автора](#) находится тот же ONNX с ID, указанным в original_source карточки OMZ, и [конфигурация обучения](#): sources=[['veri', 'veriwild'], ['universemodels']]. Конфигурация имеет 2019 байт, SHA-256 d939a7b35268e41420b4520b6763bf437bc417e971d8560bf1a847c31b2b231a. Имена и версия экспортированного графа проверяются по самому ONNX; эта конфигурация не является полным журналом экспорта.

Датасет	Как использован	Версия, доступ и условия
Набор организатора LCT 2026, задача №7	Подбор, калибровка, абляции; вход дообучения combined_v1 (train-часть)	Именованной версии нет; идентификация по SHA-256 ниже. Доступ через кабинет организатора. Отдельная лицензия/прямой URL архива не приложены
RoundaboutHD	Дообучение combined_v1: 511 ID / 6 068 кадров ReID-сабсета	MIT по карточке репозитория данных Bath (с оговоркой о формулировке — datasets-open/REPORT.md §6); полный локальный архив проверен 21.09: 8 075 314 494 байта, SHA-256 fad611b70065bb67dbd7eb6a1c03280b8c1252fe46c291537ccd0b9230f1dd54; точный отбор кадров и связь с combined — training/src/README.md

Датасет	Как использован	Версия, доступ и условия
CARLA-ReID	Дообучение combined_v1: 605 ID / 7 260 кадров	Apache-2.0 на репозиторий (подтверждена GitHub API); данные лежат на Dropbox без отдельного файла лицензии — та же оговорка; локальный архив: 2 529 020 889 байт, SHA-256 55153a24d2c6c95eb88d9eb44b93b03f7cdd c05f28dbc58e03c4c4a5e913908d; рецепт и отбор — training/src/README.md
VeRi-776	Предобучение OSNet и сравнивавшегося FastReID	Семейство VeRi-776; точный архив автора весов, размер и SHA-256 неизвестны . Официальный доступ по запросу; некоммерческое использование
VERI-Wild	Предобучение OSNet	В upstream не зафиксировано, какой выпуск/ревизия архива; нельзя автоматически подставлять 2.0. Размер и SHA-256 неизвестны. Доступ по запросу, некоммерческое использование
CompCars	Предобучение OSNet, объединение с VMRRdb	Датасет 2015 года; точные части и ревизия набора автора весов неизвестны. Инструкция загрузки . Только некоммерческие исследования, ограничено дальнейшее распространение; размер/SHA-256 использованных архивов неизвестны
VMRRdb	Предобучение OSNet, объединение с CompCars	Датасет из публикации 2017 года; полный набор или подмножество автора весов не указаны. Архив автора . В репозитории MIT, отдельное подтверждение условий для всех изображений отсутствует; размер/SHA-256 использованного архива неизвестны
ImageNet	FastReID Model Zoo указывает ImageNet-предобучение backbone	Точная ревизия и исходный checkpoint не указаны в переданных материалах. Изображения нами не скачивались. OSNet YAML также включает pretrained=True, но происхождение его исходной инициализации полностью не установлено

Изображения RoundaboutHD и CARLA-ReID нашей командой скачаны и использованы для дообучения combined_v1 (состав и хэши собранного набора — [training/combined/journal.md](#), [datasets-open/REPORT.md](#) §5); VeRi, VERI-Wild, CompCars, VMRRdb — только готовые веса, сами изображения нами не скачивались. Публичный checkpoint с MIT/Apache-лицензией не заполняет отсутствующие сведения о версиях обучающих данных. Полная цепочка их происхождения остаётся документированным пробелом по разделам 7 и 12 ТЗ; нельзя писать, что все использованные данные безусловно открыты и воспроизводимы.

Отпечатки фактически выданного набора

```
train.csv          9556 строк  536677 байт
bd1df45b052ae9aabb7fd356898e244875f8cad2f111a3f76977c1b90bce9268
test_query.csv     1110 строк   54288 байт
97eled21942bae9c95b1ce2e5d339d9f635bf49fa484367e6b19349789bb9b4c
test_gallery.csv   750 строк   36693 байт
a64ed21fa39bbfd8c7a172468d043415800500b6ed695cdb8162188cf9005496
```

Изображения: **11 416 файлов, 7 503 286 826 байт**. SHA-256 текстового манифеста по всем изображениям — 8274bf0d792e3b4fee1009f6fae7649466c296cfffcb359c670150a587473cc4a. Чтобы получить тот же манифест независимо от локали, выполните из DATA_DIR:

```
python3 - <<'PY'
import hashlib
from pathlib import Path
manifest = hashlib.sha256(); count = total = 0
for p in sorted(Path('images').iterdir()):
    if not p.is_file():
        continue
    with p.open('rb') as f:
        digest = hashlib.file_digest(f, 'sha256').hexdigest()
    manifest.update(f'{digest} images/{p.name}\n'.encode())
    count += 1; total += p.stat().st_size
print(count, total, manifest.hexdigest())
PY
```

Эта дополнительная команда требует Python 3.11+ и читает все изображения. Сам data/README.md имеет SHA-256 b517186daf5186f8ace0b3d2feb9fbce328cd09e620f22b84ff9a2a292d4575c.

Внешний код и статические ресурсы

Источник	Закреплённая версия / лицензия / проверка
FastReID для сравнения модели	commit c9bc3ceb2f7a6438b62fb515ea3df6d1e999e95d, Apache-2.0; внешний клон не включён в git решения
FastReID / Torchreid для сверки метрик	commits 7ed6240e2cb5e56e5ccd61744a3045f24ea7e62d / 6b8fe56638d81c36b7872e8e41efe18232335f2f; Apache-2.0 / MIT. Manifest с прямыми URL, размерами и полными SHA-256 , исходники и LICENSE включены в eval/sources/
MATLAB compute_AP.m, evaluation.m для сверки соглашения	person-re-ranking commit ca27f37dd88b27ee1f9dbc5668a9d0f45989ca71; те же URL/хеши в manifest. Отдельная лицензия этих файлов не установлена
Алгоритм k-reciprocal	Zhong et al., CVPR 2017; порт в проекте, NumPy float64. Проверяемый Python-исходник , commit 278f2c704e7f033b767f4158dff4febcb03a0b78a, 4250 байт, SHA-256 04bf1b5886ef06275d88be4d68d8f8cfd3ebc892e026f41e848ce294ab192b8e. У исходного репозитория нет корневого LICENSE; конкретная ревизия первоначального портирования не зафиксирована. Лицензия FastReID автоматически к этому файлу не приписывается
Swagger UI	5.29.5 , Apache-2.0, релиз , LICENSE . Локальные файлы — service/app/static/vendor/; отдельный LICENSE рядом с ними не приложен

Источник	Закреплённая версия / лицензия / проверка
Qdrant	v1.15.5 , исходники , Apache-2.0; Docker-образ docker.io/qdrant/qdrant:v1.15.5

Отпечатки Swagger: `swagger-ui-bundle.js` — 1 510 312 байт, `a646692ba5c95a74f99bb2c15ac879dec9a0001a72aed133ad65068da9e90c97`; `swagger-ui.css` — 155 212 байт, `bc5e8d5c013477cf1f35e2fb8ba1ddf66be0f72f24e669a509635657145e1acb`; `favicon.png` — 628 байт, `3ed612f41e050ca5e7000cad6f1cbe7e7da39f65fca99c02e99e6591056e5837`. Проверка: `sha256sum 04-solution/service/app/static/vendor/*`.

10. Полный список библиотек и версии среды

Сдаваемый контейнер

Python **3.13.15**, Linux x86_64; корневая исследовательская `.venv` — Python **3.13.13**. Исходный образ сборки: `python:3.13-slim`, проверенный image ID

`51cce855bb6e44a8ff6ed0f46ded8850f246bfc7549801459f83fc34b80c210f`, registry digest `sha256:9d2e5553305c7c7b0097999bb17187c69b921ccd6bc9d40e4bb5ebe652c00285`. Проверенный Qdrant digest: `sha256:0fb8897412abc81d1c0430a899b9a81eb8328aa634e7242d1bc804c1fe8fe863`. Dockerfile/Compose сейчас используют теги, поэтому эти digest описывают проверенную среду, но не принуждают будущую сборку к ней.

Прямые зависимости: ONNX Runtime 1.30.0 (MIT), NumPy 2.5.3 (BSD и лицензии включённых компонентов), Pillow 12.3.0 (MIT-CMU), FastAPI 0.141.1 (MIT), Uvicorn 0.53.0 (BSD-3-Clause), python-multipart 0.0.32 (Apache-2.0), qdrant-client 1.19.0 (Apache-2.0). Версии из [requirements.txt](#) установлены и проверены `pip check`.

Полный результат `pip freeze --all`, включая транзитивные зависимости и установщик; те же 31 строка лежат в репозитории как [requirements-lock.txt](#) и подставляются в сборку `constraints`-файлом:

```
annotated-doc==0.0.5
annotated-types==0.8.0
anyio==4.15.1
certifi==2026.7.22
click==8.5.0
fastapi==0.141.1
flatbuffers==25.12.19
grpcio==1.84.0
h11==0.16.0
h2==4.4.1
hpack==4.2.0
httpcore==1.0.9
httpx==0.28.1
hyperframe==6.1.0
idna==3.19
numpy==2.5.3
onnxruntime==1.30.0
packaging==26.3
pillow==12.3.0
pip==26.2.1
portalocker==3.2.0
protobuf==7.36.1
pydantic==2.13.5
pydantic_core==2.46.5
python-multipart==0.0.32
qdrant-client==1.19.0
starlette==1.6.0
```

```
typing-inspection==0.4.4
typing_extensions==4.16.0
urllib3==2.7.0
uvicorn==0.53.0
```

Этот список фиксирует фактическую проверенную **CPU-сборку** и подключён к Dockerfile.cpu как constraints — в офлайн- и сетевой ветвях. Проверено пересборкой (офлайн, --no-cache --pull=never --network none): pip freeze --all совпал с файлом построчно, pip check без замечаний. Полным lock-файлом с хешами wheel он не является. GPU-образ имеет отдельный [requirements-gpu-lock.txt](#): ONNX Runtime GPU 1.20.2 и закреплённые CUDA 12.2/cuDNN 9 библиотеки. Версии Python-пакетов не означают подтверждённого исполнения CUDA на RTX A5000; это проверяется запуском обеих моделей и замером на самом GPU. Список системных библиотек CPU-образа можно получить docker run --rm --network none vehicle-reid-service-cpu dpkg-query -W.

Фактическое обучение combined_v1

Обучение шло **19.09 на Windows**, D:\lct-reid\py312\python.exe, Quadro M2000M. Исторический журнал подтверждает torch **2.5.1+cu118**, Python 3.12. Проверка этой сохранившейся среды 21.09: **Python 3.12.8**, torch **2.5.1+cu118**, CUDA runtime **11.8**, cuDNN **90100**, драйвер **538.18**, NumPy **2.1.3**, Pillow **11.0.0**, ONNX **1.17.0**. Полный freeze всех установленных пакетов и результат повторного экспорта — [windows-environment.json](#). Это текущий снимок сохранённой среды, **не записанный в момент старта lock**; историческую неизменность всех транзитивных версий подтвердить нельзя.

Seed **20260916**, torch seed по этапам seed + stage, dev/sampler отдельно описаны в [training/src/README.md](#). Trainer включает cudnn.benchmark=True: побитовое повторение независимого обучения не гарантируется. Конфиги этапов 1/2, полные журналы и исходники с проверенными SHA-256 — там же; этап 3 по воротам не запускался. Повторный экспорт сохранённого stage2.pt совпал с поставляемым ONNX по SHA-256. Whitening считался отдельно на CPU worker-vm, среда job_45 сейчас: Python **3.14.3**, NumPy **2.4.6**, ONNX Runtime **1.30.0**, Pillow **12.3.0**; [полный снимок](#). Среда FastReID с torch 2.14.0+cpu ниже к обучению combined_v1 не относится.

Исследовательские окружения

Это окружение **не нужно** ни для сборки образа, ни для запуска сервиса, ни для команд R/T/V: они целиком живут в контейнере. Оно нужно только тем, кто хочет открыть исследовательские скрипты 04-solution/postproc/, 04-solution/plate-ablation/, 04-solution/eval/ вне контейнера. Само по себе оно их не «чинит»: промежуточные .npy и каталоги work/ в git не входят (раздел 11), так что скрипты всё равно упрутся в недостающие входы — часть понятным сообщением, часть трейсбеком (см. раздел 8). Окружение убирает только одну помеху — ModuleNotFoundError: No module named 'onnxruntime'.

Корневая .venv в git не входит; создаётся с нуля так (нужна сеть):

```
python3 -m venv "$REPO/.venv"
"$REPO/.venv/bin/pip" install onnxruntime==1.30.0 numpy==2.5.3 pillow==12.3.0 onnx==1.22.0
```

Команда закрепляет четыре прямые зависимости, но не транзитивные. Список ниже — исторический снимок, а не обещание точного результата новой установки: в проверке 23.09 resolver выбрал protobuf==7.36.2 вместо 7.36.1. pip freeze --all показывает фактически установленное окружение; версия pip зависит от используемого Python/venv (в сохранённой среде — 26.2.1). Дальше скрипты запускаются своим интерпретатором, например "\$REPO/.venv/bin/python" 04-solution/plate-ablation/scripts/eval_variants.py.

Сохранённый freeze корневой .venv (инспекция графа, baseline, метрики, постобработка, абляции; последующее добавление FAISS отражено ниже):

```
flatbuffers==25.12.19
ml_dtypes==0.6.0
numpy==2.5.3
onnx==1.22.0
onnxruntime==1.30.0
packaging==26.3
pillow==12.3.0
pip==26.2.1
protobuf==7.36.1
typing_extensions==4.16.0
```

Зависимость `onnx==1.22.0` нужна для инспекции ONNX и не включена в `runtime`. Файл [eval/requirements.txt](#) задаёт диапазон `numpy>=1.24,<3`, а не точную версию; опубликованные численные сравнения проверены с NumPy 2.5.3.

Полный freeze отдельного окружения сравнения FastReID:

```
filelock==3.32.3
fsspec==2026.7.0
Jinja2==3.1.6
MarkupSafe==3.0.3
mpmath==1.3.0
networkx==3.6.1
numpy==2.5.3
pillow==12.3.0
pip==24.3.1
PyYAML==6.0.3
setuptools==78.1.0
sympy==1.14.0
tabulate==0.10.0
termcolor==3.3.0
torch==2.14.0+cpu
typing_extensions==4.16.0
yacs==0.1.8
```

Построение исследовательских графиков также использует **matplotlib**, отсутствующий в корневой `.venv` и `runtime`. При аудите в системном Python обнаружены: Matplotlib 3.10.9, NumPy 2.2.6, Pillow 12.3.0, contourpy 1.3.3, cycycler 0.11.0, fonttools 4.61.0, kiwisolver 1.5.0, packaging 24.2, pyparsing 3.1.2, python-dateutil 2.8.2, six 1.17.0. Это снимок доступной вспомогательной среды; единый lock исходного построения всех рисунков не сохранён.

Обход Python-импортов и файлов зависимостей проведён по всем каталогам `04-solution/`, включая `review` и проверочные исходники. Неиспользованные модели/датасеты из обзорных списков `02-research/` не являются зависимостями результата. `combined_v1` действительно обучался на GPU, а не является заготовкой. Его фактические исходники теперь в `training/src/`; `.worker-payload/` содержит также установочные материалы этой среды и не входит в поставку.

Дополнительные зависимости исследований и проверок

Повторная сверка импортов и сохранённых окружений 22.09 выявила зависимости, которые не входили в приведённый выше `runtime` и ранее не были раскрыты здесь:

Использование	Библиотека / инструмент и версия	Подтверждение и границы
Измеренный ANN-бенчмарк	faiss-cpu 1.15.0 , NumPy 2.5.3, packaging 26.3; Python 3.13.15 на worker	scaling/REPORT.md , поле <code>environment.packages</code> в прогоне на 10⁶ векторов . Это исследовательский индекс, HTTP API остаётся на Qdrant

Использование	Библиотека / инструмент и версия	Подтверждение и границы
Съёмка UI через Chrome CDP	websocket-client — историческая версия неизвестна; версия браузера также не записана	Импорт websocket в ui-checks/shoot.py ; lock этого прогона в репозитории не найден. Текущая установленная версия не доказывает историческую
Ранние PyTorch-эксперименты	torchvision 0.20.1+cu118 , torch 2.5.1+cu118	Импорты в training/attempt-2/reid_train.py ; точные wheel-версии и SHA — снимок Windows . Это снимок от 21.09, а не lock всех прежних прогонов
Вспомогательные облачные smoke-скрипты	open_clip_torch 3.3.0 , timm 1.0.29 , transformers 5.17.0 известны только из Windows-снимка; версии этих пакетов в облачном прогоне неизвестны	Импорты в smoke.py . Наличие в Windows не подтверждает установку тех же версий в облаке и использование для d1_j48
Облачная заготовка окружения и Blender smoke	onnxruntime-gpu 1.26.0 , torch 2.14.0+cu126 , Blender / bpy 4.5.14 LTS — версии из рецепта	cloud/REPORT.md , blender-smoke.py . Полный freeze GPU-окружения отсутствует; это не среда, в которой получены сдаваемые векторы

Полные сохранённые списки Windows (46 пакетов) и CPU-postprocess (7 пакетов) даны в полях `pip_freeze_all` файлов [windows-environment.json](#) и [postprocess-environment.json](#). Они включают транзитивные зависимости, установщик и вспомогательные пакеты; их наличие в среде не означает вызов каждого пакета при обучении. Заимствованные исследовательские рецепты в 02-research/training-v2/recipe-details/ также импортируют NVIDIA Apex; подтверждения их исполнения и версии Apex для сдаваемого результата нет. Импорт в сохранённом чужом рецепте не приписывается рабочему trainer.

Сверка 22.09: **31/31** строка runtime в этом разделе совпала с requirements-lock.txt; metadata **30/30** поставляемых wheels совпали по именам и версиям с lock, pip приходит из базового образа. Обнаруженные внешние зависимости перечислены, но полного исторического lock исследовательских сред и списка версий всех системных библиотек в Git нет. Поэтому требование §12 о полном перечне с версиями выполнено для Python runtime, а для всего жизненного цикла решения остаётся частичным.

11. Известные ограничения и недостающие материалы

- **Обучение combined_v1 раскрыто:** [фактические исходники, конфиги, команды, SHA-256 и ограничения provenance](#). Полное переобучение в исправлении не выполнялось; отсутствие исторического source-lock и полного freeze на дату запуска не заменено предположениями.
- **Полная исследовательская воспроизводимость пока не достигнута.** Часть скриптов содержит /home/artem/projects/... и ссылки на временные work/, metadata/, evaluator_snapshot/, .ids, .npy, которых нет в git. Команда R обходит эти зависимости для основных метрик, но не восстанавливает все старые эксперименты.
- **Абляция пластины — не доказательство полного отсутствия использования ГРЗ, но проверена для обеих сдаваемых моделей.** Для combined_v1 маскирование зоны номера статистически неотличимо от контрольной зоны той же площади (все контрасты накрывают 0, [training/combined/REPORT.md §5](#)); для исходного OSNet — [plate-ablation/](#). Исходной ручной разметки/детекций/эмбеддингов вариантов в git нет — числа берутся из сохранённых json. Верхнюю границу +0.016 mAP нельзя называть «меньше процента метрики».

- **Не полностью известны версии внешних обучающих архивов и часть условий их распространения.** RoundaboutHD и CARLA-ReID теперь идентифицированы хешами полных локальных архивов и точным отбором в [training/src/](#); исторический журнал содержал только хеши производных combined-файлов. Ревизия HuggingFace/неизменяемый удалённый URL не были записаны; скачанный ныне архив надо сверять с опубликованным SHA-256; цепочка происхождения предобучения OSNet (VeRi, VERI-Wild, CompCars, VMRRdb) остаётся документированным пробелом. Все обнаруженные источники раскрыты в §9; отсутствующие сведения названы отсутствующими.
- **Веса и CPU-резерв поставлены.** Оба ONNX и whitening входят в Git; Python wheels и базовые образы для офлайн-сборки Dockerfile.cpu лежат в [wheels/](#) и [offline/](#). Этот CPU-путь проверен на Docker Engine 29.7.2 / Compose 2.40.3 ([отчёт](#)). Основной GPU-образ скачивает CUDA/cuDNN-пакеты при сборке; в Git они не входят. Данные организатора предоставляются отдельно. Реальный GPU-инференс и его скорость на стенде жюри остаются непроверенными до доступа к нему.

12. Комплект решения

Точка входа в проект — корневой [Readme.md](#). В репозитории команды размещены исходный код, конфигурация, релизные веса и офлайн-зависимости для запуска без доступа к интернету. Проверочный прогон и состав артефактов описаны в §7–8; исходные изображения организаторов передаются отдельно.

Материал	Где посмотреть
Исходный код	Открытый репозиторий команды на GitHub : Readme.md, SOLUTION.md, обучение и инференс, Dockerfile, Compose, зависимости, обе ONNX-модели и whitening; зеркало для организаторов — закрытый SourceCraft
Результаты на выданном тесте	submission.csv , embeddings.npy , candidates.csv и manifest прогона
Презентация	PDF на 16 слайдов и редактируемый PPTX ; обязательные страницы шаблона сохранены
Работающий прототип	Сайт проекта и сервис поиска ; резервный вход — через сайт
Документация	Этот текст доступен в PDF ; исходник — SOLUTION.md в репозитории

13. Сервис, собственное ML-ядро и публикация

Демонстрация через настоящий API

Дополнительно к основному docker-compose.yml сервис предлагает GET /api/demo с двумя разрешёнными query-кадрами и bbox из test_query.csv: один пример поиска и отдельный пример отказа. Кадр скачивается как оригинальные байты; клиент вызывает обычный /api/search. Ответ не записан заранее. Если локальный набор отсутствует, список демонстрации пуст. GET /api/materials возвращает только реально установленные по allowlist документы и артефакты с размером и SHA-256; GET /materials/{id} скачивает их. Полный deck с контактами в этом каталоге не размещается. После загрузки другого кадра/bbox либо нового поиска старый ответ, разбор и выгрузка не должны относиться к новому запросу. После визуальной проверки прежний запрос с

почти совпадающим кадром галереи заменён. В новом примере первые кандидаты сняты с других точек, рамка охватывает машину целиком; [проверка и хеши](#). У закрытого test нет меток личности и камер: этот экран показывает реальное ранжирование, а не доказанный межкамерный успех.

Интерфейс различает отказ (успешный ответ с пустым списком), ошибку файла, 409 без gallery и 503 при недоступном хранилище. На первом экране есть реальный демо-путь, крупные кадры, bbox мышью/касанием/точными числами, парное сравнение, честная шкала косинусной близости и экспорт текущего результата. Объяснение относится к первой OSNet; сходство поиска — к ансамблю с whitening, поэтому цифры не выдаются за одну и ту же оценку. OCR не выполняется, но область номерной пластины остаётся частью изображения; абляция в §11 ограничена.

Отдельный ML-эксперимент и решение о релизе

Все пары cosine/KR mAP в этом разделе относятся к **исследовательскому full-ranking протоколу с общим KR по всем query**, сохранённому для честного сравнения опытов. Это не официальная mAP@10 текущего submission.csv.

Исходный combined_v1 уже является нашей дообученной сетью. Новый [эксперимент distill-20260925](#) добавил обученную residual-голову к замороженному combined_v1: вход/выход 512, скрытый слой 256, distillation нормированных векторов и межкамерных отношений. Один seed, 30 эпох основного прогона и одна абляция 30 эпох. Train/dev разделены по vehicle_id (1071/100); исторический dev уже использовался при отборе backbone, а подтверждающая val многократно применялась в прошлых экспериментах. Это существенное ограничение силы вывода, не новый нетронутый holdout.

На одном протоколе val 1110 query × 750 gallery, 832 с парой, market camera исключение: d1_j48 cosine/KR full-ranking mAP **0,731609/0,774092**; student **0,707940/0,745935**; fusion с весом student=0,25 **0,731071/0,766010**. Отдельный CPU batch-1 p95 с двумя потоками, 40 попарно чередуемых примеров: d1_j48 **619,39 мс**, student **452,38 мс**, fusion **791,37 мс**. Student снизил p95 примерно на 27 %, но дельта KR mAP −0,02816, парный CI95 по vehicle_id [−0,04397; −0,01309]; cosine CI также ниже нуля. Ни student, ни fusion не выполняют заранее записанные критерии приёмки. **Сдаваемой остаётся d1_j48**, checkpoint/ONNX и честный отрицательный отчёт сохранены отдельно. Старые пороги не перенесены на student; его отказ калибровался на dev отдельно для cosine/KR. Историческое обучение release whitening использовало dev, что прямо отмечено в отчёте.

Самостоятельное ядро «из кадра в признак»

Residual student выше обучался на готовом признаке и не является самостоятельным image encoder. По отдельному заранее зафиксированному протоколу реализован и обучен [CrossViewCore](#): один MobileNetV3-Small с публичной ImageNet-инициализацией, нашими global/local ветвями 256+128+128, межкамерным sampling/loss и полным fine-tune backbone. ONNX принимает RGB-кроп 208×208 и выдаёт нормированный вектор 512 без вызова OSNet или whitening. Один CPU-прогон на данных организатора: 6639 fit-кадров, 609 dev-кадров, 14 эпох × 600 батчей, 43 минуты, checkpoint SHA 22fc2fdd92519ae21f08eb6feef3812dc92bb5dd0191b2f6c7f1bbdc6a966e1a. GPU worker не смог начать реальный батч из-за нехватки RAM хоста; его чужие процессы не завершались. Обученный ONNX — 4,90 МБ. Все метрики и входные хеши сохранены в [результатах](#).

На том же повторно использованном val mAP cosine/KR: отдельное ядро **0,276749/0,311518**, исследовательская fusion 0,25 **0,725141/0,755009**, базовая d1_j48 в том же протоколе **0,731609/0,774092**. Для core val TNR отказа равен **0** при выбранных только на dev порогах; высокий presence F1 этого не исправляет. Парный bootstrap по vehicle_id: KR ΔmAP core −0,462573, CI95 [−0,509323; −0,415570]; fusion −0,019082, CI95 [−0,035499; −0,003246]. Обученная core на одинаковых входах/CPU быстрее по batch-1 p95: **2,19 мс против 71,64 мс** (≈32,7×), но fusion даёт 93,17 мс. Эта граница замера — готовый тензор → признак, без JPEG/API/Qdrant/KR; её нельзя сопоставлять напрямую с указанным выше бенчмарком student на другом узле. Torch↔ONNX проверены на всех 1860 кадрах: top-1 и отказ совпали на 1110 запросах для cosine/KR. Независимая

проверка подтвердила отрицательное решение. **Ни core, ни fusion не проходят заранее заданные критерии; релиз остаётся d1_j48.** Этот результат не доказывает невозможности другого компактного ядра.

Ядро дообучено с сохранённого checkpoint: 12 эпох на 6639 собственных fit-кадрах с дистилляцией дескриптора и межкамерных сходств от релизного ансамбля. Заранее объявленное второе продолжение прошло 8 эпох на 19 967 fit-кадрах. Учитель использовался только при обучении одиночного image encoder; новый ONNX самостоятельно строит 512D признак из RGB-кропа. Обе попытки были заморожены до новой оценки val, веса fusion и пороги выбраны только по dev. Протоколы, SHA, таблица cosine/KR, отказ, скорость и независимая проверка — в [отчёте продолжения](#).

На той же **повторно использованной** val одиночное ядро после own/combined продолжений достигло KR mAP **0,323997/0,327450** против **0,774092** у d1_j48; combined fusion с релизом — **0,762604**, парная Δ mAP $-0,011487$ с CI95 $[-0,026954; +0,003198]$. TNR отказа обоих одиночных вариантов равен нулю. На одинаковом CPU в парном тесте готового тензора combined core имело batch-1 p95 **1,727 мс** против **43,861 мс** у релиза; это не полная задержка HTTP. Холм по восьми заявленным сравнениям и проверка Torch↔ONNX выполнены. Значимого выигрыша fusion и нужного качества одиночного ядра не получено; **сдаваемая d1_j48 не меняется**. Checkpoint, ONNX и fit-цели опыта хранятся локально вне комплекта сдачи.

Для прямой сверки с текущим выпуском из сохранённых fresh-эмбеддингов обеих моделей построен submission.csv по одному независимому top-50 алгоритму и оценён официальным evaluate.py на том же validation-сплите (832 запроса в зачёте): **d1_j48 mAP@10 0.7411030506 / Rank-1 0.7079326923, CrossViewCore после combined-продолжения 0.2979721523 / 0.2560096154**. В cosine без KR соответствующие mAP@10 — 0.7242262382 и 0.2736657223. Это повторно использованная валидация, а не результат закрытого теста; сравнение поддерживает решение не менять релиз.

Репетиция и VPS

[Развёртывание](#) фиксирует VPS, внешний HTTPS-маршрут, измеренные задержки, офлайн-кандидат, seed gallery, healthcheck, Compose и откат. В репетиции 28.09 проверены bundle fcb038a с d1_j48 и API-образ 6e8c1c9 с обновлёнными демонстрационными входами; это датированная проверка HTTP-сервиса. Новый пакетный выпуск от 29.09 зафиксирован отдельно в [manifest](#). Лендинг и документы размещены отдельно. Доступность новой публикации нужно проверять по внешним HTTPS-адресам после синхронизации. Последний срок изменений сдаваемой версии — **29.09 23:59 МСК**; после него коммиты приведут к аннулированию работы.